

Универзитет у Београду – Електротехнички факултет

МАСТЕР РАД

на тему

Синтеза видео записа на основу говорног сигнала употребом рекурентних неуралних мрежа

кандидат:

Вељко Шешел, 3253/2018

ментор:

доц. др Предраг Тадић

август, 2020.

Захвалница

Садржај

Списак слика	4
Увод	5
1 Обележја говора	6
1.1 Кепструм	7
1.2 Мел-фреквенцијски кепстрални коефицијенти	8
1.2.1 Мелова фреквенцијска скала	8
1.2.2 Мелова банка филтара	9
1.2.3 Алгоритам израчунавања МФКК	10
1.2.4 Динамичка обележја	10
1.3 Приказ обележја говора	11
2 Обележја видеа	13
3 Рекурентне неуралне мреже	14
3.1 Преглед вештачких неуралних мрежа	14
3.2 Рани модели рекурентних неуралних мрежа	16
3.3 Обучавање рекурентних неуралних мрежа	18
3.4 Модерне архитектуре рекурентних неуралних мрежа	19
3.4.1 <i>LSTM</i> модел	20
3.4.2 <i>BRNN</i> модел	22
4 Резултати обучавања модела	24
5 Синтеза видеа	25
Литература	26

Списак слика

1.1	Мел-фреквенцијска скала	8
1.2	Говорни фреквенцијски опсег подељен на 10 мел филтара	9
1.3	Насумични нормализовани аудио сигнал из базе	11
1.4	Приказ гласовних обележја	11
1.4a	Први МФКК	11
1.4b	Делта првог МФКК	11
1.5	Приказ гласовних обележја	12
1.5a	Шести МФКК	12
1.5b	Делта шестог МФКК	12
1.6	Приказ гласовних обележја	12
1.6a	Дванаести МФКК	12
1.6b	Делта дванаестог МФКК	12
3.1	Шематски приказ вештачког неурона	14
3.2	Шематски приказ вишеслојне <i>feedforward</i> неуралне мреже	15
3.3	Шематски приказ одмотане рекурентне неуралне мреже у времену	17
3.4	Шематски приказ Џордановог модела	18
3.5	Шематски приказ Елмановог модела	18
3.6	<i>LSTM</i> меморијска ћелија	20
3.7	<i>Input gate</i>	21
3.8	<i>Forget gate</i>	21
3.9	<i>Output gate</i>	22
3.10	Шематски приказ одмотане бидирекционе рекурентне неуралне мреже у времену	23

Увод

1 | Обележја говора

Први корак у синтези лажног видеа из говора је одређивање карактеристичних обележја говорног сигнала. Компонентне аудио сигнала треба да су довољно добре да носе лингвистичку компоненту, али и да су отпорне на позадински шум и на остале сметње. Једна од основних претпоставки везаних за обраду говорног сигнала јесте да се говор може приказати као излаз линеарног, временски променљивог система, чија се својства споро мењају са временом. То води ка основном принципу анализе говора који каже да ако се посматрају довољно кратки сегменти говорног сигнала, да се тада сваки сегмент може моделирати као излаз линеарног, временски инваријантног система [1]. Стога се кратки сегменти говора могу описати конволуционом једначином

$$s(t) = e(t) * \theta(t) \quad (1.1)$$

при чему $s(t)$ представља резултатни говорни сигнал, $e(t)$ представља побудну ваздушну струју (екситацију) и $\theta(t)$ импулсни одзив органа говорног тракта. У рачунарској обради говора, сигнале је згодније посматрати у дискретном домену

$$s[n] = e[n] * \theta[n] \quad (1.2)$$

Зависно од типа екситације, говорни гласови (фонеме) се могу поделити у три дистинктне категорије:

- звучни гласови
- фрикативи (беззвучни гласови)
- пловиви

Код звучних гласова, ваздух прелази преко затегнутих гласних жица које почињу да вибрирају релаксираним осцилацијама, производећи квази-периодичне четвртке које ће побудити вокални тракт. Типични представници звучних гласова су самогласници. Побуда која производи фрикативе је окарактерисана широким спектралним садржајем као што је случајни шум (глас „ш”). Пловиви настају побудом која је високог интезитета и кратког трајања (попут Дираковог импулса) (гласови „б”, „п”, „т”...). Променом облика вокалног тракта мења се фреквенцијски садржај побуде и као резултат се добијају различити фонеме. Енглески језик разликује 42 фонема.

Проблем говорне анализе представља одређивање параметара екситације и параметара имплусног одзива вокалног тракта. Овај проблем се може назвати и проблемом раздвајања конволуционих компоненти, што је познато под називом де-конволуција.

1.1 Кепструм

Кепструм дискретног сигнала $s[n]$ се може израчунати помоћу формуле [2]

$$c_s[n] = \mathcal{F}^{-1}(\log(|\mathcal{F}(s[n])|)) \quad (1.3)$$

где су са \mathcal{F} и \mathcal{F}^{-1} означене дискретна Фуријеова трансформација (ДФТ) и инверзна ДФТ. Применом ДФТ на једначину 1.1 добија се

$$S(f) = E(f) \cdot \Theta(f) \quad (1.4)$$

Израчунавање кепструма може се сматрати системом за деконволуцију због чињенице да логаритам производа две компонентне представља збир логаритмованих компоненти

$$\log |S(f)| = \log |E(f) \cdot \Theta(f)| \quad (1.5)$$

$$= \log |E(f)| + \log |\Theta(f)| \quad (1.6)$$

$$= C_E(f) + C_\Theta(f) \quad (1.7)$$

Применом инверзне Фуријеове трансформације добија се кепструм говорног сигнала

$$c_s[n] = \mathcal{F}^{-1}(C_E(f) + C_\Theta(f)) \quad (1.8)$$

$$= \mathcal{F}^{-1}(C_E(f)) + \mathcal{F}^{-1}(C_\Theta(f)) \quad (1.9)$$

$$= c_e[n] + c_\theta[n] \quad (1.10)$$

У облику сигнала $c_s[n]$ уочљиве су области у којима доминирају еквиваленти ваздушне побуде $c_e[n]$, односно импулсног одзива говорних органа $c_\theta[n]$. Утицај ваздушне побуде доминантнији је при већим вредностима аргумента, док ниже вредности аргумента носе информацију о импулсном одзиву вокалног тракта. Због тога се најчешће користи првих 12 кепстралних коефицијената, док нулти коефицијент носи информацију о енергији сигнала.

Пошто је говор реалан сигнал, амплитуда спектра $|S(f)|$ је парна функција и кепструм ће имати реалне вредности

$$c_s[n] = \mathcal{F}^{-1}(\log(|\mathcal{F}(s[n])|)) \quad (1.11)$$

$$= \frac{1}{N} \sum_{k=1}^{N-1} \log(|\mathcal{F}(s[n])|) e^{\frac{j2kn\pi}{N}} \quad (1.12)$$

$$= \frac{1}{N} \sum_{k=1}^{N-1} \log(|\mathcal{F}(s[n])|) \left(\cos\left(\frac{2kn\pi}{N}\right) + j \sin\left(\frac{2kn\pi}{N}\right) \right) \quad (1.13)$$

$$= \frac{1}{N} \sum_{k=1}^{N-1} \log(|\mathcal{F}(s[n])|) \cos\left(\frac{2kn\pi}{N}\right) \quad (1.14)$$

Због овог својства, често се уместо инверзне дискретне Фуријеове трансформације користи дискретна косинусна трансформација ради смањења комплексности израчунавања.

1.2 Мел-фреквенцијски кепстрални коефицијенти


Претходно описани поступци се често користе у применама везаним за аутоматско препознавање говора. У циљу опонашања људског начина доживљавања различитих учестаности у фонетима и примењујући кепстралну анализу настају Мел-фреквенцијски кепстрални коефицијнти (МФКК).

1.2.1 Мелова фреквенцијска скала

Мел-скала је усклађена са људским осећајем висине гласа односно његове учестаности. Њено добијање се врши експериментално, слушаоцу се репродукује тон учестаности 1000 Hz и као његово запажање о висини овог тона се бележи вредност 1000 mel, и ова вредност се користи као мера упоређивања за даље добијање мел скале. Затим се учестаност повећава све док слушаалац не примети тон који слуша има дупло већу висину од упоредне вредности и та висина означава вредношћу од 2000 mel. Овај се принцип добија за добијање осталих вредности скале. Експерименти су ипак показали да је међусобна зависност мела и херца лиенарна до 500 Hz, док изнад ове учестаности једнаким променама мела одговара све већа промена у херцима. За конвертовање фреквенције у мелову скалу и назад могу се користити формуле

$$M(f) = 1125 \log \left(1 + \frac{f}{700} \right) \quad (1.15)$$

$$M^{-1}(m) = 700 \left(\exp \left(\frac{m}{1125} \right) - 1 \right) \quad (1.16)$$




Слика 1.1: Мел-фреквенцијска скала

1.2.2 Мелова банка филтара

Постојање аудиторних критичних опсега је такође особина која условљава људски доживљај различитих учестаности. Ова појава везана је за чујни доживљај слушаоца приликом слушања два различита тона на различитим учестаностима. Дакле, уколико се слушаоцу пусти тон учестаности f_1 која се налази у неком чујном опсегу, тада слушалац има доживљај тона у складу са мел склаом. Уколико се поред тог тона пусти други тон учестаности f_2 тада звучни доживљај слушаоца зависи од међусобне фреквентне блискости ова два тона. Наиме, уколико је фреквентни размак довољно мали тако да се налазе унутар истог критичног чујног опсега долази до појаве маскирања и слушалац чује тон f_1 , али веће гласности. Уколико је фреквентни размак ових тонова већи од ширине чујног критичног опсега тада слушалац чује два тона на одговарајућим претходно поменутиим учестаностима. Имајући то у виду фреквенцијски опсег говорног сигнала потребно је изделити на опсеге. Ти опсези формирају мелову банку филтара. Поступак формитања мелове банке филтара се може изделити на кораке:

1. Користећи јендачину 1.15 конвертовати доњу и горњу границу говорног сигнала у мелову скалу. За доњу границу се може узети вредност од 0 Hz, док је горња фреквенција обично условљена Никвистовим креитеријумом. У коришћеном скупу података, говорни сигнал је одабиран са 16 kHz, па је за горњу границу коришћена вредност од 8 kHz.
2. Изделити опсег говорног сигнала на меловој скали на еквидистантне делове (опсеге). За број делова се обично узима број из интервала [26, 40]. За n филтара добијају се $n + 2$ фреквенције на меловој скали.
3. Добијене мелове фреквенције, потребно је вратити у Hz фреквенције, формулом 1.16, које се касније користе за централне учестаности троугаоних филтара



Слика 1.2: Говорни фреквенцијски опсег подељен на 10 мел филтара

1.2.3 Алгоритам израчунавања МФКК

У овом поглављу ће бити приказан детаљан поступак добијања МФКК.

- **Високофреквентно филтрирање**

Говорни сигнал је по природи аналогни сигнал, који је потребно дискретизовати и дигитализовати да би се израчунала тражена обележја. Поменути процеси су нискофреквентни и утичу на слабљење виших спектралних компоненти у говорног сигнала. Из тог разлога након извршене дигитализације, а пре самог издавања обележја, потребно је извршити предобраду снимљеног говорног сигнала. То се постиже применом високопропусног филтра првог реда

$$H(z) = 1 - az^{-1} \quad (1.17)$$

при чему се параметар a бира из интервала $[0.95, 0.98]$ [2].

- **Прозоровање сигнала**

На почетку поглавља је речено да се само кратки сегменти говора могу сматрати као излаз линеарног, временски инваријантног система. Са тим у вези сигнал је потребно изделити на прозоре дужине $20\text{ ms} - 40\text{ ms}$ [1]. У овом раду изабрана је дужина прозора од 25 ms , са преклапањем између суседних прозора од 15 ms . Наредни кораци се примењују за сваки прозор.

- **Израчунавање спектра снаге**

За сваки прозор говорног сигнала је првобитно потребно одредити ДФТ. Ради потискивања бочних лобова, згодно је применити Хамингов прозор пре израчунавања ДФТ. У овом раду ДФТ се израчунава у 512 тачака. Спектар снаге се може естимирати периодограмом, који за сигнал $s[n]$ се израчунава по формули

$$S(f) = \mathcal{F}(s[n]) \quad (1.18)$$

$$P(f) = \frac{1}{N} |S(f)|^2 \quad (1.19)$$

- **Филтрирање спектра снаге меловом банком филтара**

Добијени периодограм је потребно филтрирати кроз сваки филтар из мелове банке. Добијени коефицијенти за сваки филтар се сумирају. На крају се добијају коефицијенти који нам говоре колико је енергије садржано у сваком филтру филтер банке.

- **Логаритмовање**

Логаритмовати сваки коефицијент добијен пропуштањем периодограма кроз банку филтара.

- **Дискретна косинусна трансформација**

Дискретном косинусном трансформацијом над логаритмованим енергијама добијају се кепстрални коефицијенти.

1.2.4 Динамичка обележја

Често је од интереса посматрати и промену МФКК у времену [2]. На овај начин, коришћена обележја директно носе информацију о променама између сусед-

них прозора говорног сигнала. Ради израчунавања ових обележја користе се полиномијалне апроксимације првог и другог извода кепстралних коефицијената [3]


$$\Delta c_t = \frac{\sum_{n=1}^N n(c_{t+n} - c_{t-n})}{2 \sum_{n=1}^N n^2} \quad (1.20)$$

$$\Delta^2 c_t = \frac{\sum_{n=1}^N n(\Delta_{t+n} - \Delta_{t-n})}{2 \sum_{n=1}^N n^2} \quad (1.21)$$


где су Δc_t и $\Delta^2 c_t$ делта и делта-делта кепстрални коефицијенти за прозор t , израчунати из статичких кепстралних коефицијената из околних прозора. Типична вредност која се узима је $N = 2$.

1.3 Приказ обележја говора


У овом раду, као вектор улазних параметара, коришћено је 13 кепстралних коефицијената, са њихом делтама, што даје улазни вектор димензије 26. Уместо првог кепстра, коришћена је енергија сигнала. Из базе видео фајлова, само аудио снимци су извучени уз помоћ алата *FFmpeg* [4], чиме се добија база аудио снимака говора председника Обама. Након тога, сваки видео је нормализован уз помоћ *FFmpeg - normalize* додатка [5]. Приказ неких кепстралних коефицијената, за насумично одабран аудио снимак из базе, се може погледати у наставку.




Слика 1.3: Насумични нормализовани аудио сигнал из базе



Слика 1.4: Приказ гласовних обележја




(a) Шести МФКК




(б) Делта шестог МФКК

Слика 1.5: Приказ гласовних обележја



(a) Дванаести МФКК



(б) Делта дванаестог МФКК

Слика 1.6: Приказ гласовних обележја


2 | Обележја видеа

3 | Рекурентне неуралне мреже

Неуралне мреже су модели учења који остварају огроман успех у широком спектру задатака супервизираних и несупервизираних машинског учења. Класичне (*feedforward*) неуралне мреже се посебно издвајају у проблемима класификације. Упркос њиховој моћи, стандардне неуралне мреже имају ограничења, од којих је назначајније да примери из базе података морају бити међусобно независни. У случају када су подаци зависни у времену и простору ово није прихватљиво. Фрејмови видеа, делови аудио сигнала, речи из реченице представљају примере података где захтев о међусобној независности није задовољен. Рекурентне неуралне мреже превазилазе тај недостатак и користе се у случајевима када се подаци могу приказати у форми секвенце. Оне имају особину да селективно прослеђују информацију између корака секвенце, док и даље процесују један по један корак. У овом поглављу ће се прво бацити кратак осврт на класичне (*feedforward*) неуралне мреже, а затим ће бити детаљније обрађен појам различитих врста рекурентних неуралних мрежа.

3.1 Преглед вештачких неуралних мрежа

Неуралне мреже су модели израчунавања инспирисани биолошким неуралним системом. Неурална мрежа се састоји од скупа вештачких неурона, који се још и називају чворовима, који су међусобно повезани синапсама (везама). За сваки неурон j се дефинише функција активације $l_j(*)$ и интеграциона функција $f_j(*)$. Веза од чвора j' ка чвору j је описана тежинским коефицијентом $w_{jj'}$.




Слика 3.1: Шематски приказ вештачког неурона

За интеграциону функцију се најчешће узима линеарна сума, те се вредност на излазу једног чвора може израчунати као

$$v_j = l_j \left(\sum_{k=0}^i w_{ji} v_i \right) \quad (3.1)$$

Чести избори активационе функције су сигмоид $\sigma(z) = 1/(1 + e^{-z})$ и хиперболички тангенс $\tanh(z) = (e^z - e^{-z})/(e^z + e^{-z})$. Од скоро, у моделима дубоких неуралних мрежа користи се активациона функција $ReLU(z) = \max(0, z)$ која је показала значајно побољшање перформанси.

Feedforward неуралне мреже су врста вештачких неуралних мрежа чији усмерени графови не смеју да садрже петље. Због одсуства петљи, чворове мреже је могуће организовати у слојеве. Излаз једног слоја се добија на основу излаза нижих слојева.



Слика 3.2: Шематски приказ вишеслојне *feedforward* неуралне мреже

Вектор обележја \mathbf{x} се доводи на најнижи (улазни) слој. Излази чворова у наредним слојевима се сукцесивно израчунавају, док се не добије излаз највишег (излазног) слоја мреже $\hat{\mathbf{y}}$. *Feedforward* мреже се користе у супервизованом учењу на задацима класификације и регресије. Учење се остварује ажурирањем тежинских коефицијената $w_{jj'}$ са циљем да се оптимизује критеријумска функција $\mathcal{L}(\hat{\mathbf{y}}, \mathbf{y})$, која пенализује дистанцу између излазног вектора $\hat{\mathbf{y}}$ и вектора циља \mathbf{y} .

Најуспешнији алгоритам за тренирање неуралних мрежа је алгоритам пропагације у назад (енг. *backpropagation*) [6]. Алгоритам пропагације у назад користи ланчано правило за рачунање извода критеријумске функције \mathcal{L} . Тежински коефицијенти се поправљају користећи алгоритам градијентног спуста. Најчешће коришћен алгоритам градијентног спуста је градијентни спуст који користи мини шарже (енг. *batch*) обучавајућег скупа. Тај алгоритам комбинује предности шаржног и стохастичког градијентног спуста. Применом тог алгоритма коефицијенти се ажурирају на основу акумулиране грешке свих примерака из мини шарже. За шаржу дужине n правило ажурирања тежинских коефицијената се може записати овако

$$w := w - \eta \nabla_w \mathcal{L}(\hat{\mathbf{y}}^{i:i+n}, \mathbf{y}^{i:i+n}) \quad (3.2)$$

где је са η означена брзина обучавања (енг. *learning rate*). У општем случају, критеријумска функција није конвексна, и не постоји гарант да ће градијентни спуст довести до глобалног минимума. Многе варијанте градијентног спуста се уводе како би се убрзало обучавање. Неке од најпопуларнијих су: *AdaDelta* [7], *AdaGrad*

[8], *RMSprop* [9] и *Adam* [10]. Углавном се заснивају на мењању брзине обучавања као и на моментуму који представља промену тежинског коефицијента у претходној итерацији алгорита.

Да би се израчунао градијент у једначини 3.2 користи се, већ поменут, алгоритам пропагације у назад. Као што јој само име каже, алгоритам започиње од излазног слоја и креће уназад ка нижим слојевима. За чвор j , који се налази у излазном слоју, активационе функције $l_j(*)$ и линеарном интеграционом функцијом $s_j(*)$, важи једначина 3.1

$$y_j = v_j = l_j(s(w_{ji}, v_i)) \quad (3.3)$$

$$= l_j\left(\sum_{k=0}^i w_{ji}v_i\right) \quad (3.4)$$

За тежински коефицијент везе између чвора j из излазног слоја и чвора i из скривеног слоја, промена се може добити на следећи начин

$$\Delta w_{ji} = -\eta \frac{\partial \mathcal{L}(\hat{\mathbf{y}}, \mathbf{y})}{\partial w_{ji}} \quad (3.5)$$

$$= -\eta \left[\frac{\partial \mathcal{L}(\hat{\mathbf{y}}, \mathbf{y})}{\partial y_j} \right] \left[\frac{\partial y_j}{\partial s(w_{ji}, v_i)} \right] \left[\frac{\partial s(w_{ji}, v_i)}{\partial w_{ji}} \right] \quad (3.6)$$

$$= \eta \delta_{ji} v_i \quad (3.7)$$

$$\delta_{ji} = - \left[\frac{\partial \mathcal{L}(\hat{\mathbf{y}}, \mathbf{y})}{\partial y_j} \right] \left[\frac{\partial y_j}{\partial s(w_{ji}, v_i)} \right] \quad (3.8)$$

$$= - \left[\frac{\partial \mathcal{L}(\hat{\mathbf{y}}, \mathbf{y})}{\partial y_j} \right] l'_j(s_j) \quad (3.9)$$

Величина δ_{ji} се назива и сигналом грешке. Први чинилац у изразу 3.8 зависи од избора критеријумске функције, а други представља извод активационе функције $l'_j(*)$. За тежински коефицијент везе између чвора који припада скривеном слоју i и чвора који се налази у слоју иза l важи

$$\Delta w_{il} = -\eta \frac{\partial \mathcal{L}(\hat{\mathbf{y}}, \mathbf{y})}{\partial w_{il}} \quad (3.10)$$

$$= -\eta \left[\frac{\partial \mathcal{L}(\hat{\mathbf{y}}, \mathbf{y})}{\partial v_i} \right] \left[\frac{\partial v_i}{\partial s_l} \right] \left[\frac{\partial s_l}{\partial w_{il}} \right] \quad (3.11)$$


$$= \eta \delta_{il} v_l \quad (3.12)$$

$$\delta_{il} = l'_l(s_l) \sum_k \delta_{kl} w_{kl} \quad (3.13)$$

Једначина 3.13 се сукцесивно примењује за све ниже слојеве, чиме се уз сачуване вредности излаза чворова добијају градијенти појединачних тежинских коефицијената.

3.2 Рани модели рекурентних неуралних мрежа

Рекурентне неуралне мреже су мреже чији усмерени графови дозвљавају петље, чиме се уводи појам времена у модел. У тренутку t , чворови са рекурентним везама зависе од тренутног улазног вектора $\mathbf{x}^{(t)}$ и вредности стања чвора у претходном тренутку $\mathbf{h}^{(t-1)}$. Излаз чвора $\hat{\mathbf{y}}^{(t)}$, зависи од вредности стања чвора $\mathbf{h}^{(t)}$ и посредством рекурентних веза улаз улаз у тренутку $t-1$ $\mathbf{x}^{(t-1)}$ може утицати на излаз у тренутку t .



Слика 3.3: Шематски приказ одмотане рекурентне неуралне мреже у времену

Мрежа са слике 3.3 се може описати једначинама

$$\mathbf{h}^t = l_h(\mathbf{W}_{hx}\mathbf{x}^t + \mathbf{W}_{hh}\mathbf{h}^{t-1} + \mathbf{b}_h) \quad (3.14)$$


$$\mathbf{y}^t = l_y(\mathbf{W}_{yh}\mathbf{h}^t + \mathbf{b}_y) \quad (3.15)$$

где су са \mathbf{W}_{hx} , \mathbf{W}_{yh} и \mathbf{W}_{hh} матрице које садрже тежинске коефицијенте, а l_h и l_y неке активационе функције. Вектори \mathbf{b}_h и \mathbf{b}_y омогућавају учење офсета.


Истраживања на тему рекурентних неуралних мрежа су започела осамдесетих година прошлога века. Прво је Хопфилд представио фамилију рекурентних неуралних мрежа која је имала могућности препознавања шаблона [11]. Структура мреже је иста као на слици 3.3, с тим да се улазни шаблон \mathbf{x} примени само у почетном тренутку, након кога се мрежа препусти израчунавањима све док се на излазу не добије стационарна вредност. Хопфилдове мреже имају могућност да репродукује меморисане шаблоне из зашумљених шаблона које добију на улази и представљају претечу Болцманових машина и ауто-енкодера.

Рани модел за супервизовано учење секвенци је представио Џордан у [12]. Модел је *feedforward* мрежа која се састоји од једног скривеног слоја који садржи специјалне чворове. Излаз мреже је везама спојен са специјалним чворовима, који рекурентним везама, у наредном временском тренутку, достављају вредности осталим чворовима скривеног слоја. У случају да излаз мреже представља неке акције, овакав модел омогућава памећење акције из претходног временског тренутка. Неколико модерних модела користи ову идеју. Један такав примерак је рад [13] где се на примеру преводиоца језика, при генерисању текста преведених реченица, речи са краја се враћају и користе као улаз за наредни корак. Специјални чворови могу да садрже и додатну рекурентну везу тако да за улаз имају и своје претходно стање (слика 3.4).

Елманов модел из [14] представља архитектуру која личи на мрежу са слике 3.3. За разлику од Џордановог модела, који чува тренутну вредност излаза у специјалним чворовима, Елманов модел чува тренутну вредност чворова скривеног слоја, коју у наредном временском тренутку враћа тим скривеним чворовима (слика 3.5). Елман је у свом раду тренирао мрежу алгоритмом пропагације у назад и доказао да мрежа може научити зависности од времена.



Слика 3.4: Шематски приказ Џордановог модела



Слика 3.5: Шематски приказ Елмановог модела

3.3 Обучавање рекурентних неуралних мрежа

Док су у начелу рекурентне неуралне једноставан и моћан модел, у пракси њихово обучавање је комплексан процес. Међу главним разлозима су проблему нестајућег и експлодирајућег градијента, који су представљени у раду [15]. Критеријумска функција за рекурентну неуралну мрежу представља суму губитака у појединачним временским тренуцима. Ако је дужина секвенце T , она се рачуна

$$\mathcal{L}(\hat{\mathbf{y}}, \mathbf{y}) = \sum_{t=1}^T \mathcal{L}(\hat{\mathbf{y}}^t, \mathbf{y}^t) \quad (3.16)$$

Ради оптимизације критеријумске функције и даље се може користити градијенти спуст, али за рачунање градијента потребно је изменити алгоритам пропагације у назад. Модификован алгоритам се назива алгоритам пропагације у назад кроз време [16] (енг. *Backpropagation Through Time – BPTT*). Посматрајмо једноставну рекурентну мрежу са слике 3.3, са једним скривеним рекурентним слојем. За њу важе једначине 3.14 и 3.15.

$$\mathbf{h}^t = l_h(u_t) \quad (3.17)$$

$$\mathbf{y}^t = l_y(\mathbf{o}^t) \quad (3.18)$$

$$\mathbf{o}^t = \mathbf{W}_{yh}\mathbf{h}^t + \mathbf{b}_y \quad (3.19)$$

$$\mathbf{u}^t = \mathbf{W}_{hx}\mathbf{x}^t + \mathbf{W}_{hh}\mathbf{h}^{t-1} + \mathbf{b}_h \quad (3.20)$$

Једна итерација алгоритма *BPTT* се може приказати кроз следеће поступке:

1. Иницијализују се вредности промена тежинских матрица и вектора одступања: $\Delta \mathbf{W}_{hx}$, $\Delta \mathbf{W}_{hh}$, $\Delta \mathbf{W}_{yh}$, $\Delta \mathbf{b}_h$ и $\Delta \mathbf{b}_y$ на нула векторе/матрице.
2. За сваки тренутак t од T до 1:
 1. $\Delta \mathbf{o}^t \leftarrow l'_y(\mathbf{o}^t) \frac{\partial \mathcal{L}(\hat{\mathbf{y}}, \mathbf{y})}{\partial \hat{\mathbf{y}}^t}$
 2. $\Delta \mathbf{b}_y \leftarrow \Delta \mathbf{b}_y + \Delta \mathbf{o}^t$
 3. $\Delta \mathbf{W}_{yh} \leftarrow \Delta \mathbf{W}_{yh} + \Delta \mathbf{o}^t (\mathbf{h}^t)^T$
 4. $\Delta \mathbf{h}^t \leftarrow \Delta \mathbf{h}^t + \mathbf{W}_{yh}^T \Delta \mathbf{o}^t$
 5. $\Delta \mathbf{u}^t \leftarrow l'_h(\mathbf{u}^t) \Delta \mathbf{h}^t$
 6. $\Delta \mathbf{W}_{hx} \leftarrow \Delta \mathbf{W}_{hx} + \Delta \mathbf{u}^t (\mathbf{v}^t)^T$
 7. $\Delta \mathbf{b}_h \leftarrow \Delta \mathbf{b}_h + \Delta \mathbf{u}^t$
 8. $\Delta \mathbf{W}_{hh} \leftarrow \Delta \mathbf{W}_{hh} + \Delta \mathbf{u}^t (\mathbf{h}^{t-1})^T$
 9. $\Delta \mathbf{h}^{t+1} \leftarrow \mathbf{W}_{hh}^T \Delta \mathbf{u}^t$
3. Добијене вредности градијента искористити за алгоритам градијентног спушта.

Посматрајмо извод

$$\frac{\partial \mathcal{L}(\hat{\mathbf{y}}, \mathbf{y})}{\partial \mathbf{W}_{hh}} = \sum_{t=1}^T \Delta \mathbf{u}^t (\mathbf{h}^{t-1})^T \quad (3.21)$$

Вредност $\Delta \mathbf{u}^t$ се може аналитички записати

$$\Delta \mathbf{u}^t = \mathbf{W}_{yh}^T l'_y(\mathbf{o}^t) \frac{\partial \mathcal{L}(\hat{\mathbf{y}}, \mathbf{y})}{\partial \hat{\mathbf{y}}^t} \prod_{\tau=t+1}^T \mathbf{W}_{hh}^T l'_h(\mathbf{u}^\tau) \quad (3.22)$$

Ако су све сопствене вредности матрице \mathbf{W}_{yh} мање од 1, онда ће производ у једначини 3.22 са повећањем броја чинилаца тежити нули, и допринос суми у једначини 3.21 ће тежити нули. Другим речима грешка неће испропагирати до нижих временских тренутака, те се овај проблем назива проблем нестајућег градијента. Проблем експлодирајућег градијента настаје у случају када су сопствене вредности матрице већ од 1, али он може да се регулише избором погодних активационих функција и ограничавањем градијента помоћу регуларизације (енг. *gradient clipping*).

Једно решење проблема нестајућег градијента је скрећена пропагација у назад кроз време (енг. *Truncated Backpropagation Through Time – TBPTT* у коме се постави број корака у којима ће грешка пропагирати у назад [17]. Тиме се утиче на проблем нестајућег градијента, али се онемогућује учење дужих временских зависности. Учење дужих временских зависности омогућују модерније архитектуре рекурентних неуралних мрежа.


3.4 Модерне архитектуре рекурентних неуралних мрежа

Најуспешнија архитектура рекурентних неуралних мрежа која превазилази проблеме обучавања дужих временских зависности у секвенцама, представљена је у раду [18]. Овај модел се назива *Long Short-Term Memory – LSTM*. Други рад, [19],

уводи архитектуру бидирекционих рекурентних неуралних мрежа (енг. *Bidirectional Recurrent Neural Networks-BRNN*), у којој информација и из прошлости и из будућности може да се користи да се одреди излаз у сваком временском тренутку. Ово је у супротности са претходним радовима, у којима су се само улази из прошлости утицали на тренутни излаз. Такође, *LSTM* и *BRNN* је могуће комбиновати да би се добила *Bidirectional LSTM* архитектура.

3.4.1 LSTM модел

Hochreiter и *Schmidhuber* у [18] су увели *LSTM* модел примарно како би превазишли проблем нестајућег градијента. Овај модел представља стандардну рекурентну неуралну мрежу са скривеним слојем (слика 3.3), али класични чвор је замењен са меморијском ћелијом (слика 3.6).



Слика 3.6: *LSTM* меморијска ћелија

Кључна ствар у *LSTM* чвору је стање ћелије (енг. *cell state*) преко ког је омогућено кретање информације без промене. То се остварује тако што су тежински коефицијенти рекурентних веза између ћелијских стања фиксирани на 1. *LSTM* има могућност да дода или одузме информације из стања ћелије преко структуре која се назива *gate*. *Gate* се састоји од сигмоид активационе функције, која се примењује на један вектор улаза. Сигмоид функција има вредности између 0 и 1 и скалраним множењем са другим улазним вектором се одлучује колико се информације тог другог вектора преноси даље. *LSTM* чвор садржи три *gate*-а.


- **Input gate**

Овај *gate* израчунава кандидата за ново стање ћелије. Састоји се од два дела (слика 3.7). Први део рачуна новог кандидата којим ће се ажурирати вредност стања ћелије \tilde{C}_t , а други део i_t одлучује који део новог кандидата ће се додати на тренутно стање ћелије.

$$\mathbf{i}_t = \sigma(\mathbf{W}_i[\mathbf{h}_{t-1}, \mathbf{x}_t] + \mathbf{b}_i) \quad (3.23)$$

$$\tilde{\mathbf{C}}_t = \tanh(\mathbf{W}_C[\mathbf{h}_{t-1}, \mathbf{x}_t] + \mathbf{b}_C) \quad (3.24)$$

где је са $[\mathbf{h}_{t-1}, \mathbf{x}_t]$ означен здружени вектор претходног излаза ћелије и тренутног вектора улаза.




Слика 3.7: *Input gate*

- **Forget gate**

Овај *gate* одлучује колико ће се информације из претходног ћелијског стања \mathbf{C}_{t-1} задржати. Треба напоменути да је овај *gate* додат накнадно у раду [20]. Одлука се доноси на основу излаза сигмоид функције који посматра здружени вектор тренутног улаза и претходног излаза.

$$\mathbf{f}_t = \sigma(\mathbf{W}_f[\mathbf{h}_{t-1}, \mathbf{x}_t] + \mathbf{b}_f) \quad (3.25)$$

Ново стање ћелије се добија комбинацијом *forget gate*-а са претходним ста-



Слика 3.8: *Forget gate*

њем ћелије и комбинацијом *input gate*-а са кандидатом за ново стање

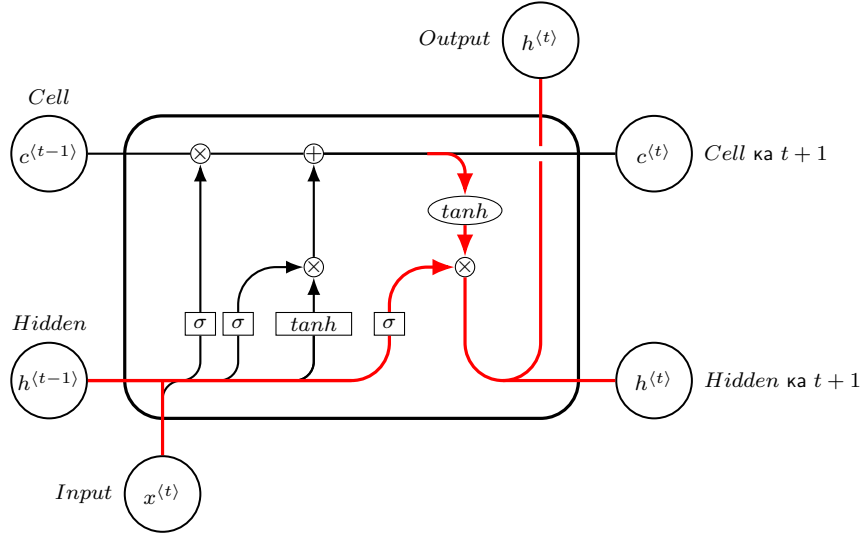
$$\mathbf{C}_t = \mathbf{f}_t \cdot \mathbf{C}_{t-1} + \mathbf{i}_t \cdot \tilde{\mathbf{C}}_{t-1} \quad (3.26)$$

- **Output gate**

Израз се рачуна на основу стања ћелије које се прво пропусти кроз \tanh , како би се вредности ограничиле на интервал $[-1, 1]$, а затим се тај вектор скаларно помножи са вектором који одлучује колико ће се стања ћелије проследити на излаз

$$\mathbf{o}_t = \sigma(\mathbf{W}_o[\mathbf{h}_{t-1}, \mathbf{x}_t] + \mathbf{b}_o) \quad (3.27)$$

$$\mathbf{h}_t = \tanh(\mathbf{C}_t) \quad (3.28)$$



Слика 3.9: *Output gate*

3.4.2 BRNN модел


У овој архитектури, постоје два слоја чворова у скривеном слоју, и оба слоја су повезана са улазним и излазним слојем. Један слој има рекурентне везе које носе информацију ис прошлих временских тренутака, док други носи информацију из наредних временских тренутака. За тренутак t и улазни вектор \mathbf{x}_t , стања и излаз мреже се могу рачунати на следећи начин

$$\vec{\mathbf{h}}_t = \sigma(\mathbf{W}_{hx}^f \mathbf{x}_t + \mathbf{W}_{hh}^f \vec{\mathbf{h}}_{t-1} + \mathbf{b}_h^f) \quad (3.29)$$

$$\overleftarrow{\mathbf{h}}_t = \sigma(\mathbf{W}_{hx}^b \mathbf{x}_t + \mathbf{W}_{hh}^b \overleftarrow{\mathbf{h}}_{t-1} + \mathbf{b}_h^b) \quad (3.30)$$

$$\hat{\mathbf{y}}_t = \sigma(\mathbf{W}_{yh}^f \vec{\mathbf{h}}_t + \mathbf{W}_{yh}^b \overleftarrow{\mathbf{h}}_t + \mathbf{b}_y) \quad (3.31)$$

Са датом улазном секвенцом, прво се израчунају стања *forward* слоја $\vec{\mathbf{h}}_t$ почевши од првог одбирка, а затим се израчунају стања *backward* слоја $\overleftarrow{\mathbf{h}}_t$ почевши од последњег одбирка секвенце. Након тога се, уз по једначини 3.31 израчуна вектор излаза. За обучавање, може се користити алгоритам *BPTT*. Једна од мања *BRNN* модела је што се не може имплементирати у реалном времену, јер је немогуће сазнати вредност улазних одбирака у будућности.



Слика 3.10: Шематски приказ одмотане бидирекционе рекурентне неуралне мреже у времену

Бидирекционе мреже могу да се комбинују са *LSTM* моделом тако што се уместо обичних *RNN* чворова користе *LSTM* ћелије.

4 | Резултати обучавања модела

5 | Синтеза видео

Литература

- [1] Буровић, Ж. Материјали са предмета Обрада и препознавање говора
- [2] Делић, В. Анализа мел-фреквенцијских кепстралних коефицијената као обележја коришћених при аутоматском препознавању говорника
- [3] <http://practicalcryptography.com/miscellaneous/machine-learning/guide-mel-frequency-cepstral-coefficients-mfccs/>
- [4] <https://ffmpeg.org/>
- [5] <https://github.com/slhck/ffmpeg-normalize>
- [6] David E. Rumelhart, Geoffrey E. Hinton, and Ronald J. Williams. Learning internal representations by error propagation. Technical report, DTIC Document, 1985.
- [7] Matthew D. Zeiler. Adadelata: an adaptive learning rate method. arXiv preprint arXiv:1212.5701, 2012.
- [8] John Duchi, Elad Hazan, and Yoram Singer. Adaptive subgradient methods for online learning and stochastic optimization. The Journal of Machine Learning Research, 12:2121–2159, 2011.
- [9] Tijmen Tieleman and Geoffrey E. Hinton. Lecture 6.5- RMSprop: Divide the gradient by a running average of its recent magnitude, 2012.
- [10] Diederik P. Kingma, Jimmy Ba, Adam: A Method for Stochastic Optimization, 2014.
- [11] John J. Hopfield. Neural networks and physical systems with emergent collective computational abilities. Proceedings of the National Academy of Sciences, 79(8):2554–2558, 1982.
- [12] Michael I. Jordan. Serial order: A parallel distributed processing approach. Technical Report 8604, Institute for Cognitive Science, University of California, San Diego, 1986.
- [13] Ilya Sutskever, Oriol Vinyals, and Quoc V. Le. Sequence to sequence learning with neural networks. In Advances in Neural Information Processing Systems, pages 3104–3112, 2014.
- [14] Jeffrey L. Elman. Finding structure in time. Cognitive science, 14(2):179–211, 1990.
- [15] Bengio, Y., Simard, P., and Frasconi, P. (1994). Learning long-term dependencies with gradient descent is difficult. IEEE Transactions on Neural Networks, 5(2), 157–166
- [16] Werbos, P. (1990). Backpropagation through time: what it does and how to do it. Proceedings of the IEEE, 78(10):1550–1560.

-
- [17] Ronald J. Williams and David Zipser. A learning algorithm for continually running fully recurrent neural networks. *Neural Computation*, 1(2):270–280, 1989.
 - [18] Sepp Hochreiter and Jürgen Schmidhuber. Long short-term memory. *Neural Computation*, 9(8):1735–1780, 1997.
 - [19] Mike Schuster and Kuldip K. Paliwal. Bidirectional recurrent neural networks. *Signal Processing, IEEE Transactions on*, 45(11):2673–2681, 1997.
 - [20] Felix A. Gers, Jürgen Schmidhuber, and Fred Cummins. Learning to forget: Continual prediction with LSTM. *Neural computation*, 12(10):2451–2471, 2000.